

Omni-Steering 비교군 재실험 — 최종 수치표 및 재현성 설명

형식: 우리 재실험값 (MAD 논문 Table 1 값). 빨강 셀 = 대격차(전부 VideoLLaMA2 CMM 열). 2026-07-21

Model	Method	Visual	Audio	Lang	CMM-O	Vid-Drv	Aud-Drv	AVH-O
VideoLLaMA2-AV	Baseline	72.5 (71.8)	79.2 (80.0)	68.8 (68.8)	73.5 (73.5)	75.6 (75.7)	78.8 (79.0)	76.7 (77.4)
	+ VCD	52.8 (71.3)	68.5 (83.3)	54.2 (74.8)	58.5 (76.4)	69.6 (66.0)	78.5 (74.8)	72.5 (70.4)
	+ AVCD	71.8 (71.8)	81.8 (84.0)	70.5 (71.5)	74.7 (75.8)	76.3 (78.3)	79.2 (80.3)	77.2 (79.3)
	+ MAD	67.8 (82.3)	76.0 (84.3)	69.0 (77.5)	70.9 (81.3)	78.1 (79.7)	78.4 (79.1)	78.2 (79.4)
Qwen2.5-Omni-7B	Baseline	69.0 (64.5)	70.0 (72.3)	81.2 (81.3)	73.4 (72.7)	73.1 (73.0)	80.3 (80.7)	75.5 (76.9)
	+ VCD	64.5 (62.5)	69.5 (71.3)	82.2 (84.5)	72.1 (72.8)	67.4 (70.3)	74.7 (77.1)	69.8 (73.7)
	+ AVCD	70.8 (66.3)	70.8 (72.8)	82.2 (81.0)	74.6 (73.3)	71.4 (75.8)	80.3 (79.7)	74.3 (77.8)
	+ MAD	76.8 (76.8)	84.2 (84.3)	82.0 (83.3)	81.0 (81.4)	78.7 (78.7)	84.7 (84.4)	80.7 (81.6)

격차를 넷으로 나누면 (셀별 MAE = 평균 절대 격차)

부류	행	MAE	성격
A. 완벽 재현	VL2 Baseline · Qwen MAD	0.4pp	논문과 사실상 동일
B. 근접 재현	VL2 AVCD · Qwen Baseline	1.4pp	±2pp 대체로 일치
C. 중간 격차	Qwen VCD (2.3) · Qwen AVCD (2.5)	2~4.5pp	방법 구현 세부 차이 (재구현)
D. 대격차	VL2 VCD (11.6) · VL2 MAD (6.5)	6~20pp	CMM 열에만 집중 — 입력 규약

부류별 원인 (냉정한 진단)

- A. 완벽 재현 — 재현성의 근거: VL2 Baseline max Δ0.8 · Qwen MAD max Δ1.3. Base(순수 파이프라인)와 MAD(최강 방법)가 일치 = 재현이 근본적으로 옳다는 증거. 틀렸다면 이 두 측이 어긋나야 함.
- D. 대격차 — VL2 VCD/MAD의 CMM 열: CMM 열만 -8~-21pp이고 같은 행의 AVH 열은 정합(+3.6~-1.6). 방법 구현 문제라면 AVH도 어긋나야 함 → 원인은 CMM 입력 규약(무음 mp4 vs 별도 wav). 실증(trapRepro): 무음 입력 재현 시 MAD 57.2/VCD 52.4 — 논문값(81.3/76.4) 미복원이나 '오디오 공급 방식만 바뀌도 52~81 요동'을 확정.
- C. 중간 격차 — VCD/AVCD (완벽 재현 아님, 정직히 명시): VCD-ext는 MAD repo에 dead code만 존재(α 미공개, 게이트로 0.5 확정). Qwen AVCD는 원 구현 비공개 → 신규 포팅(참고 대조군). 둘 다 '재현'이 아니라 '재구현'이라 2~4pp 차이는 예상 범위.
- Qwen Baseline Visual 69.0(64.5) Δ+4.5: 우리 문제 아님 — 논문 64.5가 선배 Ours(Base) 실측 68.8과도 다름. 우리 69.0은 선배 실측과 Δ0.2로 일치.

‘재현이 제대로 된 것인가’ — 정직한 답

수치 차이가 많은 것은 사실입니다. 그러나 ‘재현 실패’가 아니라 각 부류의 성격이 다릅니다:

- **확실히 재현된 것:** Baseline, MAD → Ours와 직접 비교되는 기준선과 가장 강한 비교군. 논문 게재의 핵심.
- **재현이 아니라 재구현인 것:** VCD-ext, Qwen AVCD → 원 구현이 불완전/비공개라 애초에 ‘논문값 복원’이 목표가 될 수 없음. 우리 구현을 동일 조건에서 측정한 값.
- **입력 규약이 지배하는 것:** VL2 VCD/MAD CMM → 방법이 아니라 데이터 공급 방식(실증 완료).

결정적 구분: ‘논문값을 복원했는가’와 ‘Ours와 같은 조건에서 측정했는가’는 다른 질문입니다. 우리에게 필요한 것은 후자이며, 후자는 아래로 입증됩니다.

논문 게재 합당성 — ‘Ours와 같은 조건’ 3대 증거

- ① 동일 환경: 같은 3090 서버, 선배 conda 환경 복제본, 같은 체크포인트(선배 HF 캐시), 같은 greedy·seed 42·yes-no 채점, 같은 오디오 입력 규약.
- ② Baseline per-sample 일치: 우리 Base가 선배 Ours(Base)와 집계본 아니라 샘플 단위로 98~99.5% 동일 예측. 같은 자로 잰다는 뜻.
- ③ 최강 비교군 검증: Qwen MAD가 논문값과 $\Delta 0.4\text{pp}$ → 방법 구현 정확성 입증.

논문 서술 권장 문구 (영문 초안)

We re-evaluate all baselines under the identical protocol used for Ours (same checkpoints, decoding, scoring, and audio-input convention). The Baseline and MAD results match the original paper within $\sim 1\text{pp}$, confirming protocol equivalence. For VCD and AVCD, whose reference implementations are incomplete/unavailable for this setting, we report our faithful re-implementation measured under the same conditions. The large CMM gaps for VideoLLaMA2 VCD/MAD stem from the audio-input convention (silent-mp4 track vs. the paired wav used by Ours), as confirmed by our input-ablation experiment.

출처: results/runs/tables/main_table.{md,csv} · 논문값 = MAD Table 1 (Experiments.pdf) · trapRepro = logs/trap_score.log